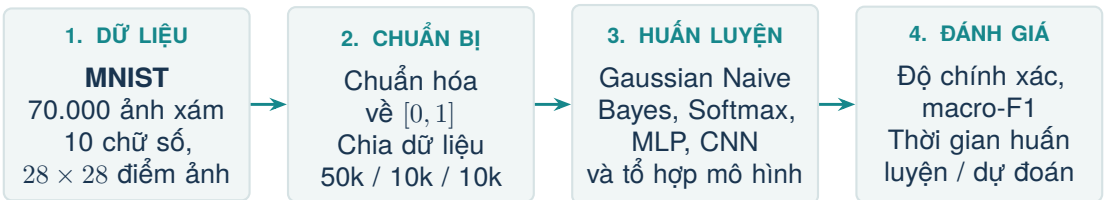
BÁO CÁO GIỮA KỲ

Nhận dạng chữ số viết tay — MNIST

Trần Hùng Luyện: 24110201 | Lê Mỹ Tài: 24110235

Quy trình



Tách thành: 50.000 ảnh huấn luyện / 10.000 kiểm định / 10.000 kiểm tra.

Khảo sát dữ liệu — phân bố lớp

DỮ LIỆU

70.000

ảnh MNIST: 60.000 huấn luyện + 10.000 kiểm tra

$28 \times 28 \rightarrow 784$

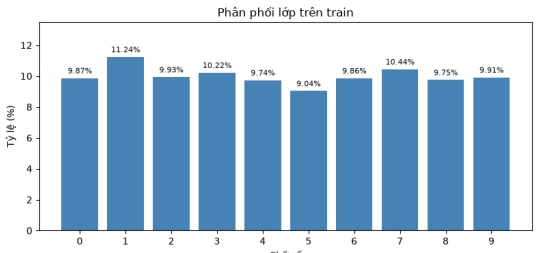
đặc trưng sau khi làm phẳng ảnh

$[0, 1]$

kiểu float32, mọi giá trị đều hữu hạn

- Tập huấn luyện được chia thành 50.000 ảnh train và 10.000 ảnh validation.
- Cả 10 lớp đều có mặt trong ba tập dữ liệu.
- Trong tập huấn luyện, lớp 1 nhiều nhất (5.618); lớp 5 ít nhất (4.518).

PHÂN BỐ LỚP

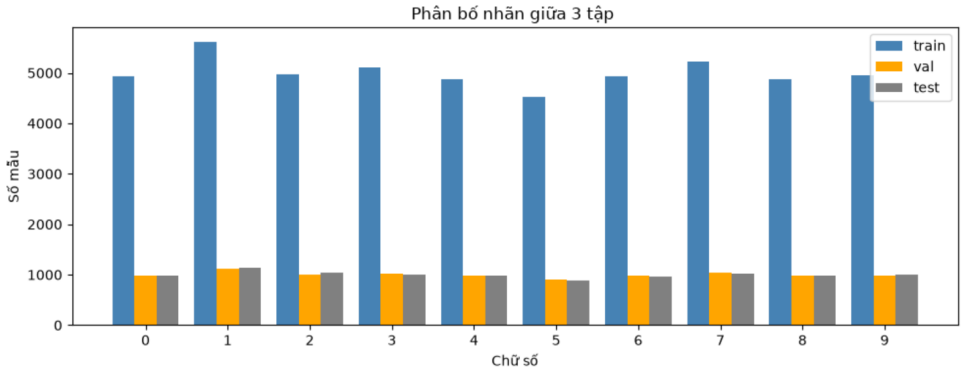


Tần suất nhãn trong tập huấn luyện

Tỷ lệ mỗi lớp nằm trong khoảng 9,04%–11,24%; dữ liệu tương đối cân bằng.

Khảo sát dữ liệu — đối chiếu ba tập

PHÂN BỐ NHÃN THEO TẬP DỮ LIỆU

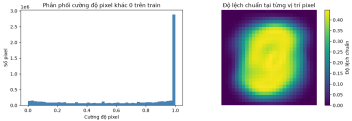


Số lượng mẫu theo chữ số trong train, validation và test

Biểu đồ này được tạo trong các notebooks của GaussNaiveBayes và MLP để kiểm tra lại các tập trước khi so sánh.

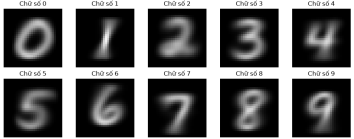
Khảo sát dữ liệu — cấu trúc ảnh

ĐỘ LỆCH CHUẨN PIXEL



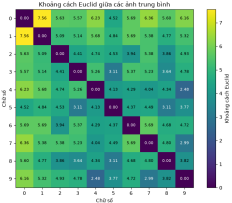
Biến thiên điểm ảnh trên tập huấn luyện

ẢNH TRUNG BÌNH



Hình dạng trung bình theo chữ số

KHOẢNG CÁCH LỚP



Khoảng cách giữa ảnh trung bình

80,86% giá trị điểm ảnh bằng 0; 0,66% bằng 1; 72 vị trí luôn bằng 0. Các cặp ảnh trung bình gần nhau nhất là 4–9, 7–9 và 3–5.

Gaussian Naive Bayes — mô hình xác suất

CÔNG THỨC MÔ HÌNH / 1 Với $x = (x_1, \ldots, x_{784})$ và lớp $c \in \{0, \ldots, 9\}$:

$$P(x \mid y = c) = \prod_{j=1}^{784} \mathcal{N}(x_j \mid \mu_{cj}, \sigma_{cj}^2).$$

$$\log P(y = c \mid x) = \log \pi_c + \sum_{j=1}^{784} \log \mathcal{N}(x_j \mid \mu_{cj}, \sigma_{cj}^2) + C(x).$$

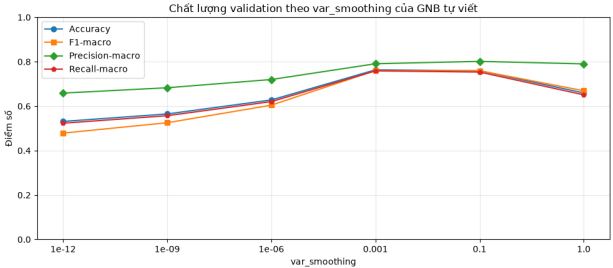
$$\hat{y} = \arg\max_c \left[\log \pi_c - \frac{1}{2} \sum_j \left\{ \log(2\pi\sigma_{cj}^2) + \frac{(x_j - \mu_{cj})^2}{\sigma_{cj}^2} \right\} \right].$$

$$\pi_c = \frac{n_c}{n}, \qquad \mu_{cj} = \frac{1}{n_c} \sum_{i:y_i=c} x_{ij}, \qquad \tilde{\sigma}_{cj}^2 = \sigma_{cj}^2 + \varepsilon.$$

Giả định độc lập có điều kiện giữa các điểm ảnh. Tính trong miền logarit tránh tràn số; ε ngăn phương sai bằng 0 ở nền ảnh.

Gaussian NB — hệ số làm trơn quyết định kết quả

KHẢO SÁT TRÊN TẬP KIỂM ĐỊNH



F1 và độ chính xác theo hệ số làm trơn

KHÁC BIỆT TRONG CÁCH TÍNH

- Các mức thử ε: $10^{-12}, 10^{-9}, 10^{-6}, 10^{-3}, 10^{-1}, 1.$
- Bản tự viết: cộng trực tiếp ε vào phương sai.
- scikit-learn: cộng $\varepsilon \max_j \mathrm{Var}(X_j)$.
- Sau khi quy đổi cùng phương sai, hai cách tính trùng khớp ở ba mức thử.

0,7600
Macro-F1 trên tập kiểm định, bản tự viết

0,7952
Macro-F1 trên tập kiểm định, scikit-learn

Cấu hình cuối: bản tự viết $\varepsilon = 10^{-3}$; scikit-learn ‘var_smoothing=0.1‘. Hai giá trị này thuộc cách đặt tham số khác nhau.

Gaussian NB — kết quả và kiểu lỗi

KẾT QUẢ TRÊN 10.000 ẢNH KIỂM TRA

	Tự viết	scikit-learn
Độ chính xác	77,53%	81,47%
Macro-F1	0,7716	0,8131
Huấn luyện (s)	0,411	0,262
Dự đoán (s)	1,147	0,333

ĐIỂM CHÍNH

89,44%

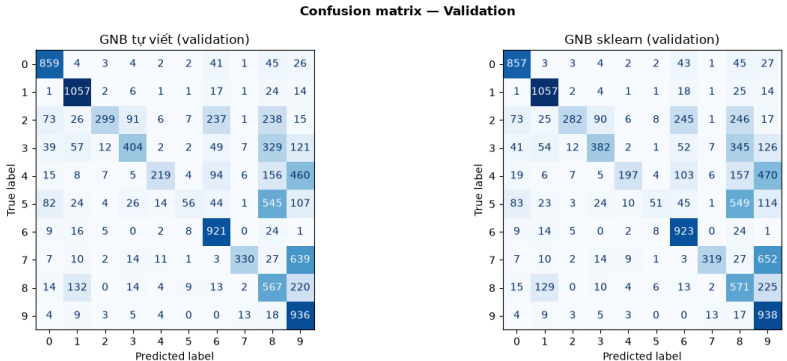
tỷ lệ dự đoán trùng nhau giữa hai cấu hình

Hai cài đặt có chất lượng khác nhau đáng kể dù cùng sử dụng Gaussian Naive Bayes.

- Cấu hình mặc định có F1 trên tập kiểm định chỉ 0,5253.
- Tăng hệ số làm trơn giúp cải thiện kết quả; hệ số quá lớn lại làm giảm khả năng phân biệt.

Kết luận: mô hình cơ sở nhanh, dễ diễn giải; hạn chế chính là giả định các điểm ảnh độc lập và bỏ qua cấu trúc không gian.

Gaussian NB — ma trận nhầm lẫn trên tập kiểm định



So sánh bản tự viết và scikit-learn trên tập kiểm định

Hồi quy Softmax — mô hình tuyến tính

CÔNG THỨC MÔ HÌNH / 2 Với $X \in \mathbb{R}^{n\times 784}$, $W \in \mathbb{R}^{784\times 10}$:

$$Z = XW + \mathbf{1}b^{\top}, \qquad p_{ik} = \frac{\exp(z_{ik})}{\sum_{r=0}^{9}\exp(z_{ir})}.$$

$$\mathcal{L}(W,b) = -\frac{1}{n}\sum_{i=1}^{n}\log p_{i,y_i} + \frac{\lambda}{2}\|W\|_F^2.$$

$$\nabla_W \mathcal{L} = \frac{1}{n}X^{\top}(P-Y) + \lambda W, \qquad \nabla_b \mathcal{L} = \frac{1}{n}\sum_{i}(P_i - Y_i).$$

$$\hat{y}_i = \arg\max_{k} p_{ik}.$$

Mô hình tuyến tính trên 784 điểm ảnh. Lưu bộ tham số khi entropy chéo trên tập kiểm định giảm; kết quả cuối dùng bộ tham số ở vòng huấn luyện thứ 58.

Softmax — hiệu chỉnh tốc độ học và hệ số L2

KHẢO SÁT THAM SỐ

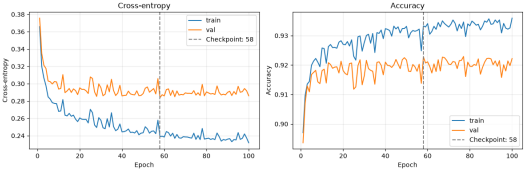
- Thử tốc độ học $\{0.001, 0.01, 0.1, 0.5, 1.0\}$ tại hệ số L2 cơ sở.
- Chọn tốc độ học 0,5: F1 trên tập kiểm định = 0,92180.
- Giữ tốc độ học 0,5, thử L2 $\{0, 10^{-4}, 10^{-3}, 10^{-2}, 2 \cdot 10^{-5}\}$.
- Chọn L2 = 2×10^{-5}; F1 cao nhất trong các mức thử.

Vòng 58
bộ tham số tốt nhất theo entropy chéo kiểm định

0,28395
entropy chéo kiểm định tại vòng 58

Thử tham số tuần tự; không khảo sát toàn bộ tổ hợp tốc độ học và L2.

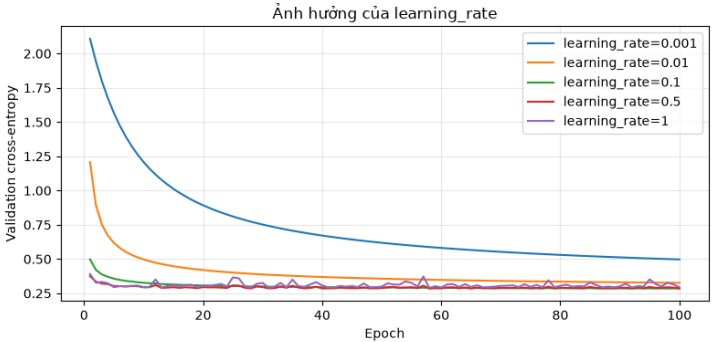
QUÁ TRÌNH HUẤN LUYỆN



Entropy chéo và độ chính xác trên hai tập dữ liệu

Softmax — ảnh hưởng của tốc độ học

ENTROPY CHÉO TRÊN TẬP KIỂM ĐỊNH



So sánh các mức tốc độ học đã thử qua 100 vòng huấn luyện

Tốc độ học 0,5 hội tụ nhanh và cho entropy chéo thấp trong các mức đã khảo sát.

Softmax — kết quả kiểm tra và giới hạn tuyến tính

KẾT QUẢ TRÊN TẬP KIỂM TRA

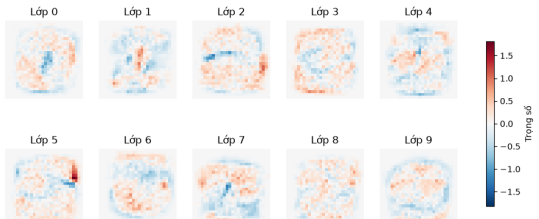
92,53%
độ chính xác — bản tự viết

0,9241
Macro-F1 — bản tự viết

92,41%
độ chính xác — scikit-learn

- Chênh độ chính xác 0,12 điểm phần trăm (12 ảnh đúng ròng).
- Huấn luyện bản tự viết mất 11,15 s; scikit-learn L-BFGS mất 431,21 s.
- Phân loại sai 747/10.000 ảnh kiểm tra.

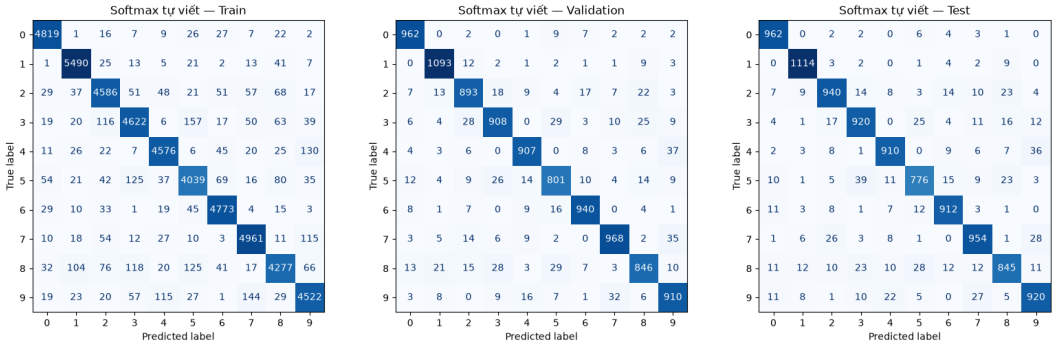
BẢN ĐỒ TRỌNG SỐ



Trọng số theo lớp, hiển thị dưới dạng ảnh 28×28

Các hướng nhầm nổi bật: $5 \to 3$ (39), $4 \to 9$ (36), $7 \to 9$ (28), $8 \to 5$ (28). Mô hình không biểu diễn tương tác phi tuyến giữa các nét.

Softmax — ma trận nhầm lẫn theo tập dữ liệu



Tập huấn luyện, kiểm định và kiểm tra

Ma trận kiểm tra ghi nhận 747 ảnh phân loại sai; các lớp 5, 4, 7 và 8 thường bị nhầm lẫn.

Perceptron nhiều lớp (MLP) — mô hình phi tuyến

CÔNG THỨC MÔ HÌNH / 3 Với các lớp ẩn $h^{(0)} = x$ và $l = 1, \dots, L$:

$$a^{(l)} = W^{(l)} h^{(l-1)} + b^{(l)}, \qquad h^{(l)} = \mathrm{ReLU}(a^{(l)}).$$

$$p = \mathrm{softmax}\left(W^{(L+1)} h^{(L)} + b^{(L+1)}\right).$$

$$\mathcal{L}(\theta) = -\frac{1}{n} \sum_{i=1}^{n} \log p_{i,y_i} + \frac{\lambda}{2} \sum_{l} \|W^{(l)}\|_F^2.$$

$$\delta^{(L+1)} = p - y, \qquad \delta^{(l)} = (W^{(l+1)\top} \delta^{(l+1)}) \odot \mathbb{1}[a^{(l)} > 0].$$

MLP — kết quả khảo sát tốc độ học và kiến trúc

TỐC ĐỘ HỌC

- Tốc độ học 0,1 tốt nhất trong miền đã thử.
- F1 trên tập kiểm định: 0,9694 (tự viết), 0,9713 (scikit-learn).

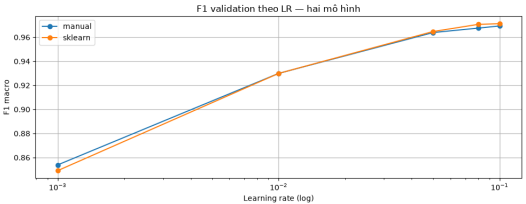
SO SÁNH KIẾN TRÚC

Lớp ẩn	Macro-F1	Thời gian (s)
(128,)	0,9604	26,8
(256,)	0,9622	30,4
(128,64)	0,9653	204,6
(256,128,64)	0,9717	399,6

- Mạng sâu hơn tăng F1 trong khảo sát này nhưng tốn thời gian huấn luyện hơn.
- Các lần thử riêng lẻ chưa đủ để xác định cấu hình tối ưu toàn cục.

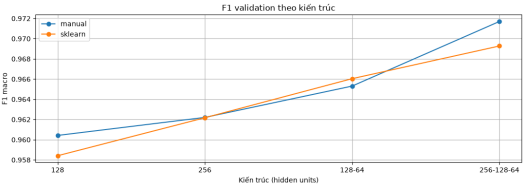
MLP — biểu đồ khảo sát siêu tham số

TỐC ĐỘ HỌC



F1 trên tập kiểm định theo tốc độ học

KIẾN TRÚC MẠNG

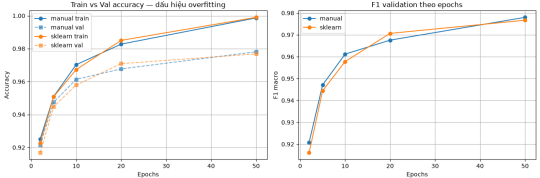


F1 theo số lượng và kích thước lớp ẩn

Kết quả minh họa sự đánh đổi giữa độ chính xác và thời gian huấn luyện.

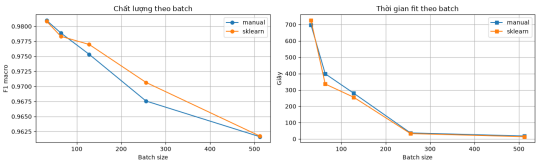
MLP — diễn biến huấn luyện và kích thước lô

ĐỘ CHÍNH XÁC THEO VÒNG HUẤN LUYỆN



Kết quả trên tập huấn luyện và kiểm định

ẢNH HƯỞNG CỦA KÍCH THƯỚC LÔ



Macro-F1 và thời gian huấn luyện

Ở epoch 50, độ chính xác kiểm định đạt 0,9781. Với Batch size = 32 đạt F1 = 0,9810 nhưng mất 698,3 s; Batch size = 512 mất 18,3 s nhưng F1 giảm còn 0,9616.

MLP — cấu hình cuối và đối chiếu cài đặt

CẤU HÌNH CUỐI

Lớp ẩn	(256, 128, 64)
Learning rate	0,1
Epoch	50
Batch size	32
L2 (tự viết)	10^{-5}
Alpha sklearn	0,01

KẾT QUẢ KIỂM ĐỊNH / KIỂM TRA

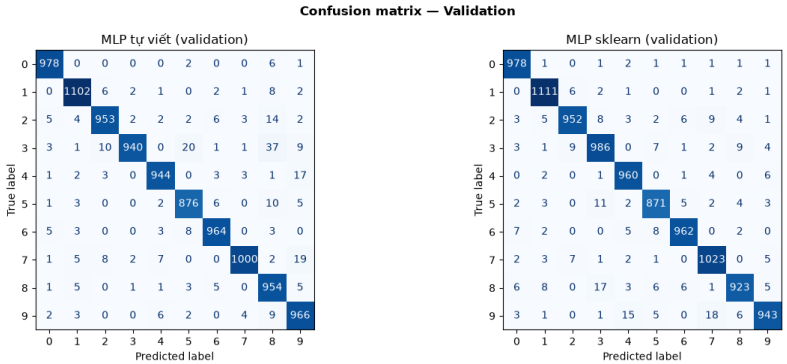
	Tự viết	scikit-learn
Độ chính xác kiểm định	98,30%	98,34%
Macro-F1 kiểm tra	0,9818	0,9840
Số lỗi kiểm tra	181	159
Huấn luyện (s)	1980,5	1960,4

98,19%
độ chính xác tập kiểm tra — tự viết

98,41%
độ chính xác tập kiểm tra — scikit-learn

Cấu hình ghép từ các khảo sát riêng, chưa tối ưu đồng thời; hai cài đặt khác hệ số L2 và cách khởi tạo.

MLP — ma trận nhầm lẫn trên tập kiểm định

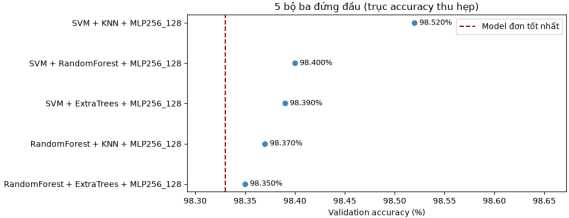


Đối chiếu MLP tự viết và scikit-learn trên tập kiểm định

Hai cài đặt cho kết quả gần nhau; lỗi tập trung ở một số chữ số có hình dạng tương tự.

Tổ hợp mô hình — chọn mô hình thành phần

SO SÁNH MÔ HÌNH THÀNH PHẦN



Macro-F1 của các tổ hợp mô hình trên tập kiểm định

- Chọn theo bỏ phiếu mềm trên tập kiểm định: SVM + KNN + MLP256_128.
- Độ chính xác kiểm định 98,52%; cao hơn SVM đơn 0,19 điểm phần trăm.
- Mỗi mô hình cung cấp vector xác suất 10 lớp.

TẠO DỰ ĐOÁN NGOÀI MẪU (OOF)

- Phân tầng 5 phần trên 50.000 ảnh huấn luyện.
- Mỗi ảnh được dự đoán bởi mô hình chưa huấn luyện trên phần chứa ảnh đó.
- Ghép 3 vector xác suất thành ma trận $Z_{\text{OOF}} \in \mathbb{R}^{50000 \times 30}$.
- Huấn luyện lại các mô hình thành phần trên toàn bộ tập huấn luyện để tạo đặc trưng kiểm định và kiểm tra.

OOF ngăn mô hình tầng hai học từ dự đoán trên chính dữ liệu đã huấn luyện; tập kiểm định vẫn được dùng để chọn mô hình và tham số.

Tổ hợp mô hình — soft voting và stacking

CÔNG THỨC MÔ HÌNH / 4 Với M mô hình nền, mỗi mô hình trả vector xác suất $p^{(m)}(x)$:

$$p_{\text{vote}}(x) = \sum_{m=1}^{M} w_m p^{(m)}(x), \qquad w_m \geq 0, \quad \sum_m w_m = 1.$$

$$\hat{y}_{\text{vote}} = \arg\max_k p_{\text{vote},k}(x).$$

Stacking học mô hình tầng hai g_ϕ từ các dự đoán ngoài mẫu:

$$z_i = \left[p_i^{(1)} \,\|\, p_i^{(2)} \,\|\, \cdots \|\, p_i^{(M)}\right] \in \mathbb{R}^{10M}, \qquad \hat{y}_i = g_\phi(z_i).$$

AdaBoost cập nhật trọng số mẫu qua các vòng:

$$\alpha_t = \eta \log \frac{1 - \text{err}_t}{\text{err}_t}, \qquad D_{t+1}(i) \propto D_t(i) \exp(\alpha_t \mathbb{1}[h_t(x_i) \neq y_i]) .$$

Trong thực nghiệm, mô hình tầng hai là AdaBoost SAMME với cây quyết định nông.

Stacking — chọn trọng số bỏ phiếu và AdaBoost

BỎ PHIẾU CÓ TRỌNG SỐ

- Thử 7 bộ trọng số: đều và tăng từng thành viên lên 2 hoặc 3.
- Trọng số tốt nhất vẫn là $(1/3, 1/3, 1/3)$.
- Bỏ phiếu có trọng số trùng với bỏ phiếu mềm: độ chính xác kiểm định 98,52%.

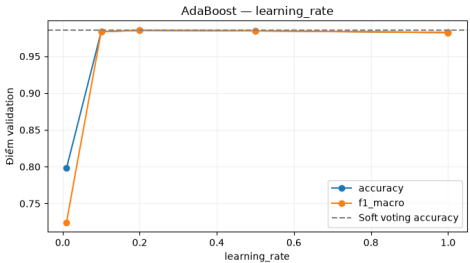
KHẢO SÁT ADABOOST

- Tốc độ học 0,2 đạt độ chính xác kiểm định 98,53%.
- Độ sâu 2, 100 cây; độ sâu 3 chỉ nhỉnh hơn trong lần khảo sát riêng.
- Tăng số cây quá 100 không cải thiện kết quả kiểm định.
- Hòa điểm: ưu tiên cây nông, ít cây hơn.

Cấu hình chọn: SAMME, tốc độ học 0,2, độ sâu tối đa 2, 100 cây. Thử tham số tuần tự, không khảo sát mọi tổ hợp.

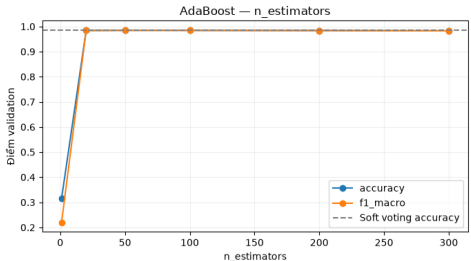
Stacking — kết quả khảo sát AdaBoost

TỐC ĐỘ HỌC



Độ chính xác theo tốc độ học

SỐ LƯỢNG CÂY



Độ chính xác theo số lượng cây

Cấu hình chọn: tốc độ học 0,2, độ sâu tối đa 2 và 100 cây quyết định.

Tổ hợp mô hình — cải thiện nhỏ, chi phí lớn

ĐỘ CHÍNH XÁC TRÊN TẬP KIỂM TRA

Mô hình	Độ chính xác	Số lỗi
KNN	97,00%	300
MLP256_128	98,26%	174
SVM	98,33%	167
Soft voting	98,52%	148
Weighted voting	98,52%	148
Stacking AdaBoost	**98,54%**	**146**

+2 ảnh
Stacking hơn soft voting trên tập kiểm tra

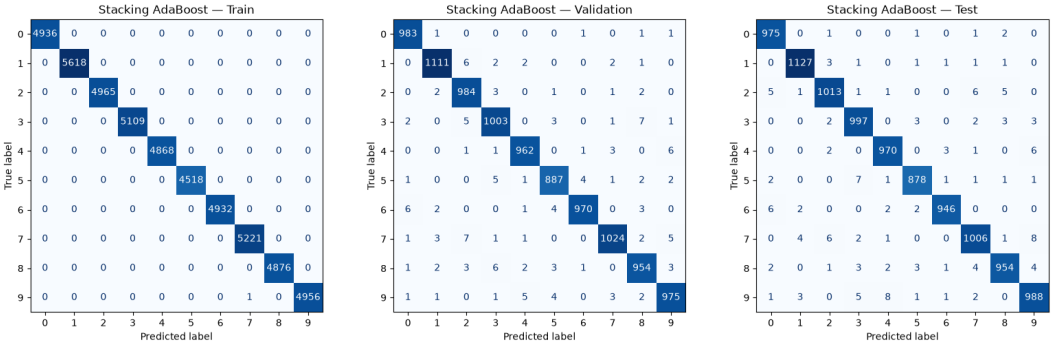
+21 lỗi ròng
Stacking so với SVM

CHI PHÍ / KIỂU LỖI

- Huấn luyện stacking mất khoảng 6.513 s; bỏ phiếu mềm mất 1.417 s.
- Dự đoán trên tập kiểm tra mất khoảng 50,7 s cho cả hai quy trình.
- Stacking sửa 20 lỗi của bỏ phiếu mềm nhưng tạo thêm 18 lỗi.

Chênh lệch hai ảnh chưa đủ kết luận stacking ổn định hơn: chỉ dùng một hạt giống và một lần chia dữ liệu.

Stacking — ma trận nhầm lẫn theo tập dữ liệu



Tập huấn luyện, kiểm định và kiểm tra

Trên tập kiểm tra, stacking đạt độ chính xác 98,54%, hơn bỏ phiếu mềm hai ảnh.

Mạng nơ-ron tích chập (CNN) — giữ cấu trúc không gian

CÔNG THỨC MÔ HÌNH / 5 Với ảnh đầu vào X và bộ lọc tích chập K:

$$(X * K)_{i,j} = \sum_{u=-r}^{r} \sum_{v=-r}^{r} K_{u,v}\, X_{i-u,j-v}.$$

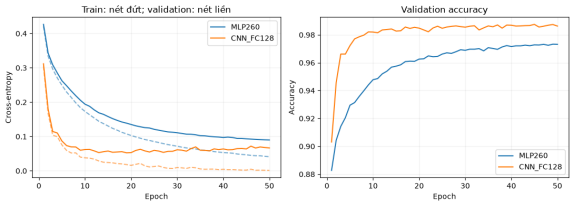
$$H^{(l)} = \mathrm{ReLU}(K^{(l)} * H^{(l-1)} + b^{(l)}), \qquad P^{(l)} = \mathrm{MaxPool}_{2\times 2}(H^{(l)}).$$

$$h = \mathrm{Flatten}(P^{(2)}), \qquad p = \mathrm{softmax}(W_2\, \mathrm{ReLU}(W_1 h + b_1) + b_2).$$

Kiến trúc thực nghiệm: $1 \times 28 \times 28 \to$ tích chập (16, 3×3) $\to$ gộp cực đại $\to$ tích chập (32, 3×3) $\to$ gộp cực đại $\to$ làm phẳng (1568) $\to$ lớp đầy đủ 128 $\to$ lớp đầu ra 10. Khác MLP, CNN khai thác lân cận điểm ảnh và dùng chung bộ lọc tại nhiều vị trí.

CNN và MLP — so sánh với số tham số gần bằng nhau

DIỄN BIẾN HUẤN LUYỆN



Mất mát và độ chính xác trong quá trình huấn luyện

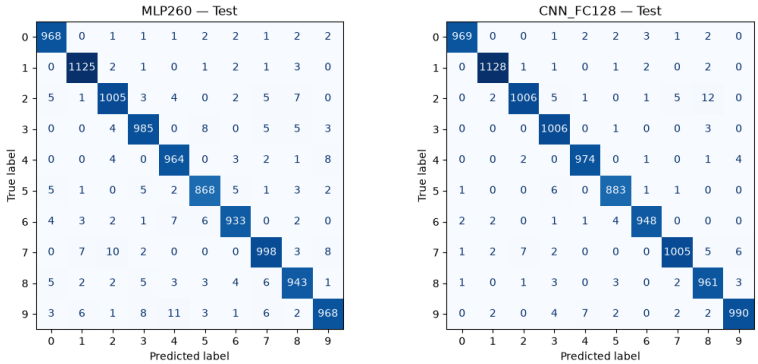
- Cùng cách chia 50k/10k/10k, hạt giống 42, SGD, lô 256.
- Chọn bộ tham số theo mất mát kiểm định: CNN ở vòng 19, MLP ở vòng 50.

KẾT QUẢ TRÊN TẬP KIỂM TRA

	MLP260	CNN-FC128
Số tham số	206.710	206.922
Độ chính xác	97,57%	**98,70%**
Macro-F1	0,9755	**0,9870**
Số lỗi	243	**130**
Huấn luyện (s)	55,8	332,5

CNN giảm 113 lỗi (46,5%) so với MLP trong lượt chạy này. Số tham số tương đương không đồng nghĩa với cùng số phép tính hoặc thời gian huấn luyện.

CNN và MLP — ma trận nhầm lẫn trên tập kiểm tra

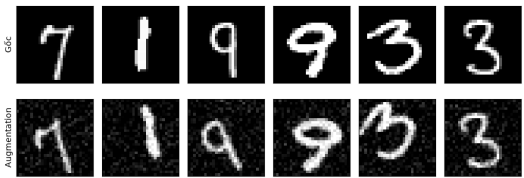


So sánh MLP260 và CNN-FC128 trên tập kiểm tra

CNN-FC128 giảm 113 lỗi so với MLP260 trong thí nghiệm này.

Tăng cường dữ liệu — tác động trên ảnh kiểm tra gốc

PHÉP BIẾN ĐỔI



Ví dụ ảnh sau biến đổi

- Xoay $\pm 30°$, dịch tối đa 4 điểm ảnh.
- Nhiễu Gaussian $\sigma = 0,1$, giá trị chặn về $[0, 1]$.
- Chỉ tăng cường ảnh huấn luyện; tập kiểm định và kiểm tra giữ nguyên.

ĐỘ CHÍNH XÁC TRÊN TẬP KIỂM TRA

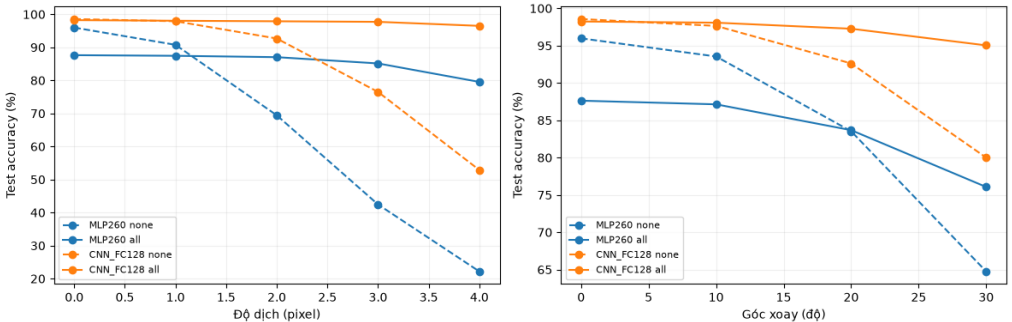
Mô hình	Gốc	Tăng cường
CNN-FC128	98,57%	98,24%
MLP260	95,98%	87,63%

Ở cấu hình 15 vòng huấn luyện, độ chính xác trên ảnh gốc giảm 0,33 điểm phần trăm với CNN và 8,35 điểm với MLP.

Kết quả chỉ phản ánh cấu hình đã thử; không suy rộng thành tăng cường dữ liệu luôn có hại.

Tăng cường dữ liệu — độ bền với phép xoay và dịch

ĐỘ CHÍNH XÁC THEO MỨC BIẾN ĐỔI



Độ chính xác theo mức dịch chuyển và góc xoay

Tăng cường dữ liệu cải thiện khả năng chịu xoay và dịch trong các mức đã thử, dù độ chính xác trên ảnh gốc có thể giảm.

Tổng hợp — bốn quy trình chính

TẬP KIỂM TRA ĐỘC LẬP / 10.000 ẢNH

Quy trình	Độ chính xác	Macro-F1	Huấn luyện (s)	Dự đoán (s)	Lỗi
Gaussian NB	77,53%	0,7716	0,41	1,10	2.247
Softmax	92,53%	0,9241	11,15	0,009	747
MLP tự viết	98,19%	0,9818	1.980,5	0,035	181
Tổ hợp AdaBoost	**98,54%**	**0,9854**	6.513,2	50,71	**146**

Chất lượng

- MLP tăng khoảng 5,66 điểm phần trăm so với Softmax.
- Tổ hợp chỉ hơn MLP 0,35 điểm phần trăm.

Chi phí

- Tổ hợp huấn luyện lâu gấp khoảng 3,3 lần MLP.
- Thời gian dự đoán dài hơn khoảng 1.457 lần trong lượt đo này.

Kết luận — ưu điểm và hạn chế

Ưu điểm	Hạn chế
Gaussian Naive Bayes: huấn luyện nhanh, dễ diễn giải; phù hợp làm mô hình cơ sở xác suất.	Giả định các điểm ảnh độc lập có điều kiện, không tận dụng quan hệ không gian; độ chính xác thấp nhất trong các mô hình đã so sánh.
Hồi quy Softmax: đơn giản, dự đoán nhanh, vượt rõ mô hình Gaussian Naive Bayes.	Ranh giới phân loại tuyến tính nên khó biểu diễn tương tác phi tuyến giữa các nét chữ.
MLP: học quan hệ phi tuyến; đạt khoảng 98,2% độ chính xác trên tập kiểm tra.	Không tận dụng trực tiếp cấu trúc lân cận của ảnh; thời gian huấn luyện tăng khi dùng mạng sâu và lô nhỏ.
CNN: khai thác cấu trúc không gian và chia sẻ bộ lọc; đạt 98,70% trong thí nghiệm so sánh.	Huấn luyện lâu hơn MLP trong thí nghiệm tương ứng; kết quả không cùng giao thức với bảng bốn quy trình chính.
Tổ hợp AdaBoost: đạt 98,54% trên bốn quy trình chính, nhỉnh hơn bỏ phiếu mềm.	Chỉ giảm hai lỗi so với bỏ phiếu mềm nhưng tốn thời gian huấn luyện và dự đoán hơn đáng kể.

Kết luận: không có mô hình tốt nhất cho mọi mục tiêu; cần cân đối độ chính xác, tốc độ và chi phí. Kết quả dựa trên một hạt giống và một lần chia dữ liệu.

Cảm ơn

Hỏi đáp